

ПРИМЕНЕНИЕ АЛГОРИТМОВ ДВУМЕРНОГО АНАЛИЗА ГЛАВНЫХ КОМПОНЕНТ ДЛЯ ЗАДАЧ РАСПОЗНАВАНИЯ ИЗОБРАЖЕНИЙ ЛИЦ

Н.Л. Щеголева,

кандидат технических наук, доцент кафедры математического обеспечения и применения ЭВМ Санкт-Петербургского государственного электротехнического университета (ЛЭТИ)

Г.А. Кухарев,

доктор технических наук, профессор кафедры математического обеспечения и применения ЭВМ Санкт-Петербургского государственного электротехнического университета (ЛЭТИ), профессор факультета информатики Западно-поморского технологического университета, Щецин, Польша (West Pomeranian University of Technology, Szczecin, Poland)

Адрес: г. Санкт-Петербург, ул. Профессора Попова, д. 5

E-mail: stil_hope@mail.ru, gkukharev@wi.zut.edu.pl

Представлены алгоритмы двумерного анализа главных компонент (Two-dimensional Principal Component Analysis – 2D PCA), ориентированные на обработку цифровых изображений больших размеров в условиях малой выборки. Рассматриваются два способа выполнения 2D PCA, соответствующие параллельной и каскадной формам его реализации. Оценены характеристики представленных алгоритмов. Обсуждаются возможности использования представленных алгоритмов в других областях.

Ключевые слова: двумерный анализ главных компонент, двумерное преобразование Карунена-Лоэва, распознавание изображений лиц, применение в бизнес-приложениях.

Введение

ХХI век ознаменовался переходом от простых информационных систем к использованию интеллектуальных сред — современного поколения вычислительных и информационных технологий. Примерами интеллектуальных сред являются:

- ♦ интернет, через который реализуются общение людей бизнес-сообщества (видеоконференции, консультации, почта), поиск информации и доступ к ней, интернет-маркетинг и интернет-магазины и т.д.;
- ♦ виртуальные предприятия, реализующие проекты по типу «start up», сообщества и ассоциации, реализующие обмен информацией, технологиями,

другими информационными и вычислительными ресурсами;

♦ высокоорганизованные интерфейсы систем «клиент – банк»;

♦ системы класса «Visitor Identification», реализующие распознавание или аутентификацию, например, постоянного покупателя магазина, гостя (посетителя) частного дома или офиса, пассажира международного транспорта и т.д.;

♦ системы контроля доступа к информации (базам данных, корпоративным сетям), к средствам (техническим, финансовым), к помещениям, к ресурсам (например, вычислительным).

Перечисленные примеры имеют одну очень важную общую характеристику: здесь все задачи решаются в процессе непосредственного общения человека со средой (в режиме «on-line») и, что самое важное, – этим человеком может быть только зарегистрированный пользователь, подлинность личности которого проверяется на входе в интеллектуальную среду.

Сегодня, например, сложно представить себе успешного бизнесмена без ноутбука, планшетного компьютера, смартфона или коммуникатора. Более того, в ходе круглого стола «Электронный парламент: вопросы правового обеспечения», который прошел 14 апреля 2011 г. было принято решение об обеспечении всех депутатов Госдумы шестого созыва, которые будут избраны в декабре 2011 г., личными интернет-планшетами iPad. Вскоре подобная перспектива ждет и каждое региональное правительство. Все эти мобильные устройства хранят личную и деловую информацию, сведения, содержащие коммерческую тайну, а устройства депутатов Госдумы – сведения, представляющие государственную тайну. Очевидно, что доступ постороннего человека к этой информации может стать причиной материальных потерь и/или нанести ущерб безопасности государства. И здесь одной из наиболее актуальных проблем является проблема идентификации (аутентификации) конечного пользователя подобных устройств.

Задачи идентификации (аутентификации) пользователя успешно решаются в рамках биометрических технологий. Эти идеи отражает статья [1], в которой показано использование методов анализа главных компонент (Principal Component Analysis – PCA) в задачах распознавания изображений лиц.

Однако в современных условиях развития информационных технологий и инженерии программного

обеспечения можно предложить более рациональные алгоритмы для этого метода, позволяющие более детально анализировать многомерные данные, какими являются изображения. Именно эти рациональные алгоритмы и предлагаются в настоящей статье, что отличает ее от работы [1].

Проблемы, связанные с обработкой изображений методами PCA

В задачах обработки изображений методами PCA исходными являются три базовых параметра: $\{M, N, K\}$, где M и N – число строк и столбцов исходных изображений, а K – количество изображений [2 – 4]. Первые два параметра определяют размерность DIM исходного пространства признаков $DIM = MN$. При этом обработке изображений лиц методами PCA сопутствует проблема малой выборки (Small Sample Size – SSS), когда $DIM \gg K$. Размерность исходного пространства признаков DIM определяет вычислительную сложность реализуемых алгоритмов.

Классический метод PCA [2] включает два этапа.

Первый из них – анализ главных компонент, в рамках которого по всем исходным данным определяется матрица ковариации и для нее определяются наибольшие собственные значения (главные компоненты) и матрица собственных векторов (матрица проекции). Второй этап включает одномерное преобразование в собственном базисе (или преобразование Карунена-Лоэва/Karhunen-Loeve Transform/KLT), которое использует найденную матрицу проекции.

Результат KLT представляет исходные данные как их спектр в собственном базисе, поэтому для сохранения основной информации об исходных данных достаточно использовать только несколько главных спектральных компонент [2]. При этом достигается условие:

$$DIM_{new} \ll DIM, \quad (1)$$

где DIM_{new} – размерность нового пространства признаков.

Однако статистически устойчивое решение задачи PCA/KLT в приложении к обработке изображений возможно только в случае отсутствия проблемы SSS и/или выполнения условия:

$$DIM = MN \ll K. \quad (2)$$

Варианты реализации PCA/KLT в условиях проблемы SSS показаны в работах [1, 3]. Они сводятся к предобработке исходных данных с целью уменьшения их размерности до достижения условия (2). Так в [3] решение основано на перемасштабировании каждого исходного изображения до размеров $m < M$ и $n < N$, при которых $DIM = mn \ll K$ и последующего прямого применения PCA/KLT. В [1] решение основано на декомпозиции всего набора исходных данных (общим размером $MN \times K$) в виде нескольких подматриц меньшего размера, для которых выполняется условие (2), нахождении частных решений PCA/KLT для этих подматриц и сведении частных решений к полному решению.

В настоящей статье представлены алгоритмы двумерного анализа главных компонент (2DPCA) и двумерного преобразования Карунена-Лоэва (2DKLT), специально предназначенные для обработки изображений больших размеров в условиях SSS и не требующие предобработки исходных данных с целью достижения условия (2) [4 – 6].

1. Идея и реализация 2D PCA\2D KLT

Пусть нам задан набор X , состоящий из X центрированных и нормированных к «1» изображений $X^{(k)}$ $k = 1, 2, \dots, K$ (для $k = 1, 2, \dots, K$) размером $M \times N$ каждое, и $MN \gg K$:

$$X = [X^{(1)} X^{(2)} \dots X^{(K)}] \quad (3)$$

Целью 2D PCA является определение двух матриц проекции, трансформирующих исходные данные в новое пространство признаков так, чтобы выполнялось условие минимума расстояния:

$$distance(X^{(k)} - W_1^T X^{(k)} W) \rightarrow \min, \forall k = 1, 2, \dots, K, \quad (4)$$

где W_1 , W_2 – ортогональные матрицы порядков M и N соответственно.

Параллельный алгоритм. Здесь двумерный анализ главных компонент выполняется независимо по строкам и столбцам исходных данных, и при этом определяются *два независимых собственных базиса*.

Модель вычислений в 2D PCA\2D KLT можно представить следующим образом:

$$\begin{aligned} 1.0. X &\xrightarrow{R} X_I; \\ 1.1. X &\xrightarrow{PCAr} W_1; \end{aligned} \quad (5)$$

$$\begin{aligned} 1.2. X_I &\xrightarrow{PCAr} W_2; \\ 2. Y^{(k)} &= W_1^T X^{(k)} W_2, \forall k = 1, 2, \dots, K. \end{aligned}$$

На этапе 1.0 выполняется реорганизация структуры исходных данных (3). Это реализуется как транспонирование всех матриц размером $M \times N$ в наборе X и составление нового набора данных X_I . На этапе 1.1 выполняется базовая процедура PCA относительно строк исходных данных (PCAr). На этапе 1.2 выполняется PCA относительно строк (PCAr) данных, входящих в набор X_I , или, что тоже самое, – относительно столбцов исходных данных. Результат этапов 1.1 и 1.2 – вычисление двух матриц проекции W_1 и W_2 . Этапы 1.1 и 1.2 могут быть выполнены параллельно, поскольку процедура PCAr применяется для независимых наборов данных X и X_I .

Наконец, этап 2 – это трансформация всех исходных изображений из набора X в новое пространство признаков Y . С учетом этого, на *рис. 1* представлена схема параллельного способа (5) реализации 2D PCA. Блок «R» реализует транспонирование всех матриц размером $M \times N$ в наборе X . Блоки, обозначенные как «⊗», реализуют процедуру проекции исходных данных. Пунктиром выделен блок, определяющий двумерное преобразование Карунена-Лоэва (2D KLT).




Рис. 1. Параллельный способ реализации 2D PCA.

Заметим, что в представленном методе двумерное 2D KLT реализуется по каскадной схеме: сначала исходное изображение обрабатывается по строкам, а затем полученный результат обрабатывается по столбцам (или наоборот). Это аналогично тому, как могут выполняться многие **двумерные** дискретные ортогональные преобразования изображений

[2], что, однако, противоречит способу получения собственных базисов в (5).

Каскадный алгоритм. Здесь в первом каскаде выполняется анализ главных компонент *по строкам* исходных изображений, а во втором – *по столбцам* результата первого каскада (или наоборот – сначала по столбцам, а потом по строкам результата). При этом определяются два *взаимосвязанных собственных базиса*, и 2D KLT реализуется также по каскадной схеме во взаимосвязанных базисах. Модель каскадного алгоритма запишем следующим образом:

$$X \xrightarrow{PCAr} \{W_1; X_1\} \xrightarrow{R} \tilde{X}_1 \xrightarrow{PCAr} \{W_2; \tilde{Y}\} \xrightarrow{R} Y. \quad (6)$$

Здесь: \tilde{X}_1 – данные X_1 после их реорганизации блоком «R»; выражения в фигурных скобках представляют результаты PCA\KLT по строкам и столбцам исходных изображений.

Схема вычислений, соответствующая модели (6), представлена на рис. 2. Здесь в явной форме отражен каскадный способ реализации 2D PCA\2D KLT.




Рис. 2. Структура каскадного алгоритма 2D PCA.

2. Формальное описание алгоритмов

Версия параллельного алгоритма. Вычислим две матрицы ковариации, определив их относительно *строк* («r» – row) и *столбцов* («c» – column) для исходных изображений (3):

$$C^{(r)} = \sum_{k=1}^K X^{(k)} (X^{(k)})^T \text{ и } C^{(c)} = \sum_{k=1}^K (X^{(k)})^T X^{(k)}, \quad \forall k \in K, \quad (7)$$

где $C^{(r)}$ и $C^{(c)}$ – матрицы порядков M и N соответственно.

С учетом (7) определим собственные значения и соответствующие им собственные векторы, решив следующие две задачи на собственные значения:

$$W_1^T C^{(r)} W_1 = \Lambda_1; \quad W_2^T C^{(c)} W_2 = \Lambda \quad (8)$$

При этом $W_1^T W_1 = I_1$ и $W_2^T W_2 = I_2$, а I_1 и I_2 – единичные матрицы порядков M и N соответственно; Λ_1 и Λ_2 – диагональные матрицы порядков M и N соответственно.

Трансформация исходных данных в новое пространство признаков реализуется как двумерное преобразование Карунена-Лоэва на основе собственных базисов, определяемых по (8) в следующей форме:

$$Y^{(k)} = (W_1^T X^{(k)}) W_2, \quad \forall k = 1, 2, \dots, K, \quad (9)$$

где $Y^{(k)}$ – матрицы размера $M \times N$, представляющие исходные изображения в новом пространстве признаков.

Версия каскадного алгоритма.

Выполним проекцию исходных данных так, что:

$$X_1^{(k)} = W_1^T X^{(k)}, \quad \forall k = 1, 2, \dots, K, \quad (10)$$

где $X_1^{(k)}$ – матрицы размера $M \times N$, представляющие исходные изображения (3) в новом (промежуточном) пространстве признаков; матрица W_1 была определена в (8).

Далее вычислим матрицу ковариации, определив ее относительно *столбцов* («c» – column) результата (10):

$$C^{(c)} = \sum_{k=1}^K (X_1^{(k)})^T X_1^{(k)}, \quad (11)$$

где матрица $C^{(c)}$ имеет порядок, равный N .

Вычислим для (11) собственные значения и соответствующие им собственные векторы, решив следующую задачу на собственные значения:

$$W_2^T C^{(c)} W_2 = \Lambda_2, \quad (12)$$

где W_2 и Λ_2 – матрицы порядка N .

Трансформация исходных данных (3) в новое пространство признаков реализуется теперь как двумерное преобразование Карунена-Лоэва (9) на основе собственных базисов, определяемых ортогональными матрицами проекции (8) и (12).

Редукция размерности пространства признаков

Изменим (9) так, чтобы в дальнейших преобразованиях участвовали только те собственные векторы, которые соответствуют « d » главным компонентам ($d < \min\{M, N\}$). Для этого, из выбранных собственных векторов формируются две прямоугольные матрицы: из матрицы W_1^T выбираем « d » строк, а из матрицы W_2 выбираем « d » столбцов, соответствующих « d » наибольшему собственным числам, и на их основе формируются две матрицы редукции F_1 и F_2 . Верхние границы параметра « d » выбираются исходя из критерия энергетической значимости собственных значений [5, 6]. Нижние границы параметра « d » выбираются экспериментально с учетом критерия (4). При этом $d < \min\{M, N\}$ или $d_1 < M$; $d_2 < N$, если $d_1 \neq d_2$.

Теперь выполним «усеченное» двумерное преобразование Карунена-Лоэва:

$$\hat{Y}^{(k)} = F_1 X^{(k)} F_2, \text{ где } \hat{Y}^{(k)} = \begin{bmatrix} y(1,1) \dots y(d,1) \\ y(2,1) \dots y(d,2) \\ \vdots \dots \dots \\ y(d,1) \dots y(d,d) \end{bmatrix}^{(k)}. \quad (13)$$

Матрицы F_1 и F_2 имеют размеры $d \times M$ и $N \times d$ соответственно (или $d_1 \times M$ и $N \times d_2$ в общем случае); знак « \wedge » — определяет отличие результата (13) от (9).

Результирующие матрицы в (13) имеют в общем случае размеры $d_1 \times d_2$ и представляют исходные изображения в новом пространстве признаков.

3. Характеристики разработанных алгоритмов и их отличия от известных

3.1. На реализацию полного 2D KLT (9) требуется $(NM^2 + MN^2)$ операций, а на реализацию «усеченного» 2D KLT по схеме (13) потребуется $(Md^2 + MNd)$ операций. При этом **сокращение вычислений** на этапе редукции размерности пространства признаков (РПП) можно приблизительно оценить как величину $(M + N)/d$, поскольку:

$$\frac{NM^2 + MN^2}{Md^2 + MNd} = \frac{MN(M + N)}{M(d + N)d} \approx \frac{M + N}{d}, \text{ для } d \ll N. \quad (14)$$

Например, для $M=112$ и $N=92$ (база лиц ORL [9])

и $d=10$ сокращение вычислений составит примерно 20 раз(!) на каждое изображение. С учетом параметра « K » — числа изображений, ускорение вычислений составит величину, равную примерно $K(M + N)/d$ на все исходные данные.

3.2. Результат в (13) содержит d^2 (или $d_1 \times d_2$) элементов, поэтому **степень редукции** РПП определяется соотношением MN/d^2 или $MN/(d_1 d_2)$, если $d_1 \neq d_2$.

Например, для $M=112$, $N=92$ и $d=10$ редукция размерности пространства признаков составит более чем 100 раз(!) на каждое изображение. **Таким образом, использование предложенных в статье алгоритмов ориентировано на сокращение ресурсных затрат в практических приложениях.**

3.3. Наибольший порядок матриц ковариации в (7), (12) составляет величину $DIM = \max\{M, N\}$. Это предопределяет практическую возможность решения задачи на собственные значения и стабильность этого решения даже для изображений больших размеров.

3.4. При представлении исходных изображений как совокупности строк и столбцов общее число получаемых векторов составляет величину $K(M + N)$, а размерность исходного пространства признаков определяется как $DIM = \max\{M, N\}$. Поэтому **при любых значениях** M и N соотношение «размерность/число векторов» всегда будет отвечать условию $\max\{M, N\} \ll K(M + N)$, «обходя» таким образом, проблему SSS.

4. Распознавание изображений лиц

Эксперименты выполнены на базе ORL [9], некоторые изображения которой показаны на рис. 3. База ORL охватывает 40 различных классов образов (изображений лиц людей различных наций), по 10 образов в каждом классе. Все изображения базы ORL относятся к типу «indoor», имеют размер 112 на 92 пикселя и представлены в шкале «GRAY» (256 уровней яркости).

Для лиц базы ORL характерно изменение: контраста изображений и яркости фона вокруг области лица; размера лиц, в том числе не пропорционально по осям X и Y ; поворота головы в пространстве 3D в пределах не менее $\pm 20^\circ$ по оси X , $\pm 30^\circ$ по оси Y и не менее $\pm 10^\circ$ по оси Z ; мимики лиц, прорисовки деталей лиц (их сглаживание).



Рис. 3. Примеры исходных данных.

В первом эксперименте решалась задача поиска изображений лиц по заданному тестовому образу с помощью представленного в данной статье алгоритма 2D PCA. Эксперимент был выполнен для всех 40 классов с выбором только одного образа из каждого класса для эталона и девяти других образов в каждом классе для теста. Таким образом, в формулировке задачи поиска база системы поиска содержала 40 образов-эталонов (по одному на класс), а в качестве тестовых были использованы 360 образов (по девять образов на каждый из 40 классов). В эксперименте дважды использована процедура кросс-валидации: в каждом эксперименте изменялся номер выбранного образа-эталона, а внутри каждого эксперимента изменялся параметр редукции « d » ($d = 3, 4, \dots, 10$). Всего, таким образом, выполнено $10 \times 8 = 80$ экспериментов. Модель выполненного эксперимента имеет следующий вид [6]:

ORL(40/1/9/CV){2DPCA:112×92→ $d \times d$ /KMP/L1/rank = 1},

где определены:

ORL(40/1/9/CV) – база лиц, структура данных и процедура кросс-валидации (CV);

2DPCA:112→92 $d \times d$ – использованный метод и размеры данных до и после редукции размерности пространства признаков;

KMP/L1/rank = 1 – тип классификатора, метрика и ранг результата.

Текущие результаты в каждом эксперименте оценивались как отношение количества правильно классифицированных тестовых образов к общему их числу 360. Общее число тестовых образов составило 3600 для каждого значения параметра « d ». Результат считался правильным, если на первом месте ($rank = 1$) в группе результатов находился образ из того же класса, что и тестовый образ.

В эксперименте использован классификатор по минимуму расстояния (KMP) в метрике L1.

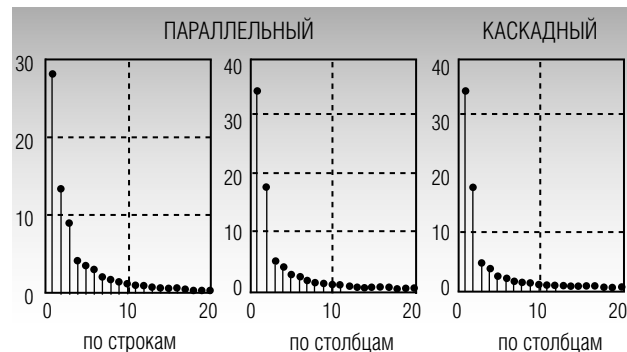



Рис. 4. Собственные значения для метода 2D PCA.

Рис. 5. К выбору параметра редукции « d ».

На рис. 4 показаны 20 наибольших собственных значений (собственные значения, вычисленные по строкам для обоих способов, – одинаковы по определению). При этом главные компоненты ограничены величиной $d \approx 6$, поскольку далее собственные значения практически равны «0».

На рис. 5 показаны результаты решения поставленной задачи поиска для различных значений параметра редукции « d ». Как видно, наилучший результат поиска получен при значении $d = 6$. Степень редукции размерности пространства признаков составила при этом значение, равное 286 (поскольку $112 \times 92 / 36 = 286$).

Подводя итоги эксперимента, необходимо отметить следующее:

♦ При выполнении поставленного эксперимента дважды решалась задача на собственные значения. Порядки матриц ковариации составили соответственно 112 и 92. Общее число «изображений» составило $40 \times (112 + 92)$, поэтому матрицы ковариации были хорошо обусловлены и не потребовалось никаких процедур их регуляризации (в подходе

«Eigenfaces» [1] порядок матрицы ковариации составил бы величину $112 \times 92 = 10304$, что сразу же определило бы невозможность ее дальнейшего использования);

♦ Ярко выраженное наличие «главных компонент» в составе собственных значений гарантирует репрезентативное представление исходных данных в новом пространстве признаков при малом значении параметра « d »;

♦ Решение поставленной задачи поиска выполнено успешно, особенно если учитывать специфику исходных данных — изображений лиц базы ORL и малое число образов-эталонов в системе поиска: по одному на каждый класс. Результаты, представленные в ходе экспериментов, выше результатов, показанных в [5], при решении аналогичной задачи.

Во втором эксперименте решалась задача распознавания изображений лиц при различном числе эталонов в базе системы распознавания (Face Recognition System — FaReS [6]). Модель выполненного эксперимента имеет следующий вид:

$$\text{ORL}(40/L/10-L/R+CV)\{2DPCA:12 \times 92 \rightarrow 8 \times 8\} \\ [KMP/L1/\text{rank} = 1].$$

В базу FaReS выбирается L тренировочных изображений в каждом из 40 классов; выбор организован случайным образом (random — R) и использована процедура кросс-валидации (R+CV). Число тестовых образов составляет $10 - L$ для $L = 1, 2, 3, 4, 5$. Результаты выполненных экспериментов представлены в *таблице 1*.

Таблица 1.

Результаты экспериментов

Э	1/40/360		2/80/320		3/120/280		4/160/240		5/200/200	
	П	К	П	К	П	К	П	К	П	К
1	68	68	78	79	93	93	94	94	97	97
2	68	68	78	78	88	89	90	90	95	96
3	70	70	82	82	90	90	94	94	95	94
4	66	68	83	84	91	90	93	93	95	93
5	71	71	83	83	90	90	91	90	92	91
6	71	71	83	83	90	90	91	92	95	95
7	70	70	87	87	91	92	93	93	96	97
8	64	64	90	90	91	91	94	95	95	95
9	67	67	82	81	89	88	90	89	94	95
10	66	68	82	82	89	89	92	92	96	96
ср	68	69	83	83	90	90	92	92	95	95

Здесь: «Э» — номер эксперимента;

1/40/360...5/200/200 — значение L и общее число изображений-эталонов и тестовых изображений в каждом эксперименте; П и К — способы: параллельный и каскадный.

Из представленных результатов видно, что существенный скачок результативности распознавания возникает уже при $L = 2$, а при значении $L = 5$ результат распознавания составляет (при округлении до наименьшего целого) в среднем 95% и в максимуме 97%. При этом результативность для двух алгоритмов реализации 2D PCA\2D KLT практически одинакова.

Эффективность применения 2D PCA\2D KLT для изображений тестовой базы FERET была показана нами в [10].

Заключение

Укажем наиболее значимые области, в которых применение алгоритмов 2D PCA/2D KLT может дать наиболее значимый эффект.

1. В [11] обосновывается необходимость применения свёртки наименьшего размера, позволяющей достигнуть наибольшей точности и производительности в процессе идентификации. Особенно актуально это для больших баз данных, хранящих информацию о биометрических характеристиках человека. Применение представленных в настоящей статье алгоритмов 2DPCA\2DKLT позволит создавать эффективные биометрические системы, обеспечивающие низкий уровень ошибок.

2. Алгоритмы 2D PCA можно использовать также для анализа и поиска закономерностей в экономических и финансовых данных, представленных многомерной структурой данных — многомерными наблюдениями. Одним из хорошо зарекомендовавших себя методов анализа и прогнозирования финансового рынка является метод «Гусеница» [12]. Метод независимо разрабатывался в России, Великобритании и США (там его аналог получил название SSA — Singular Spectrum Analysis). Суть метода заключается в формировании матриц наблюдений из множества временных рядов и выполнении PCA в приложении к этим матрицам. Применение 2D PCA\2DKLT позволит в этом случае выявить закономерности в исходных данных (тренды и их периоды, сезонные и другие периодические составляющие, взаимосвязь отдельных рядов наблюдений между собой и определить их модели), а также позволит сократить объем вычислений и объем

информации, представив исходные данные в более компактном виде.

3. Развитие методов записи и хранения данных привело к бурному росту объемов собираемой и анализируемой информации. Объемы данных настолько внушительны, что человеку просто не по силам проанализировать их самостоятельно, хотя необходимость проведения такого анализа вполне очевидна, ведь в этих «сырых» данных заключены знания, которые могут быть использованы при

принятии решений. Для того чтобы провести автоматический анализ данных, используется метод «Data Mining». Это процесс обнаружения в «сырых» данных ранее неизвестных нетривиальных практически полезных и доступных интерпретации знаний, поиска закономерностей и представление данных в виде удобном для анализа, делающее возможным построение моделей прогнозирования. Одним из методов, широко используемых в «Data Mining», является PCA. Очевидно, что алгоритмы 2D PCA будут здесь также кстати! ■

Литература

1. Мокеев А.В. О точности и быстродействии метода синтеза главных компонент // Бизнес-информатика, 2010, № 3(13). — С. 65-68.
2. Прэтт У. Цифровая обработка изображений. — М.: Мир, 1982. — 312 с.
3. Turk M., Pentland A. Eigenfaces for Face Detection // Journal of Cognitive Neuroscience, 1991, Vol. 3, №1. — P. 71-86.
4. Tsapatsoulis N., Alexopoulos V., Kollias S.A. Vector Based Approximation of KLT and Its Application to Face Recognition // Proceedings of the IX European Signal Processing Conference EUSIPCO-98, Vol. 3. — P.1581-1584.
5. Кухарев Г.А. Биометрические системы: Методы и средства идентификации личности человека. — СПб.: Политехника, 2001. — 240 с.
6. Kukharev G., Forczmański P. Data Dimensionality Reduction for Face Recognition // Journal MACHINE GRAPHICS & VISION, 2004, Vol. 13, № 1/2. — P. 99-121.
7. Кухарев Г.А., Щеголева Н.Л. Алгоритмы двумерного анализа главных компонент для задач распознавания изображений лиц // Компьютерная оптика, 2010, т.34, № 4. — С. 545-551.
8. Кухарев Г.А. Щеголева Н.Л. Системы распознавания человека по изображению лица. — СПб.: Изд-во СПбГЭТУ «ЛЭТИ», 2006. — 176с.
9. Zuo W., Wang K., Zhang H. Subspace Methods for Face Recognition: Singularity, Regularization, and Robustness // State of the Art in Face Recognition. I-Tech, Vienna, Austria, — 2004. — 250 p.
10. Кухарев Г.А. Поиск изображений лиц в больших базах данных // Мир измерений, 2009, № 4(98). — С. 22-30.
11. The ORL database - www.uk.research.att.com/pub/data/att_faces.zip.
12. Shchegoleva N.L., Kukharev G.A. Application of Two-Dimensional Principal Component Analysis for Recognition of Face Images // Pattern Recognition and Image Analysis, 2010, Vol. 20, №4. — P. 513-527. http://www.maik.ru/contents/patrec/patrec4_10v20cont.htm
13. Силантьев Д.А. Оценка необходимого размера свертки биометрического образца для обеспечения заданных параметров надежности биометрической системы идентификации // Бизнес-информатика, 2009, № 3(09). — С. 21-23.